

基于知识蒸馏的自适应多领域情感分析



杨修远,彭韬,杨亮*,林鸿飞

(大连理工大学计算机科学与技术学院, 辽宁 大连 116023)

摘要:提出一种自适应多领域知识蒸馏框架,有效地加速推理和减小模型参数同时确保模型性能,采用知识蒸馏方法对情感分析问题进行研究。针对每个特定领域进行知识蒸馏,模型蒸馏涉及词嵌入层蒸馏、编码层蒸馏(注意力蒸馏、隐藏状态蒸馏)、输出预测层蒸馏等多个方面;针对不同领域,学生模型保持相同的编码器,即共享权重,通过不同的领域特定输出层拟合不同的教师模型。在多个公开数据集上的试验结果表明,单领域知识蒸馏使得模型准确度平均提升 2.39%,多领域知识蒸馏使得模型准确度平均提升 0.5%。与单领域的知识蒸馏相比,该框架增强了学生模型的泛化能力,提升了性能。

关键词:知识蒸馏;自适应;多领域;情感分析;深度学习

中图分类号:TP391 **文献标志码:**A

引用格式:杨修远,彭韬,杨亮,等.基于知识蒸馏的自适应多领域情感分析[J].山东大学学报(工学版),2021,51(3):15-21.

YANG Xiuyuan, PENG Tao, YANG Liang, et al. Adaptive multi-domain sentiment analysis based on knowledge distillation[J]. Journal of Shandong University (Engineering Science), 2021, 51(3):15-21.

Adaptive multi-domain sentiment analysis based on knowledge distillation

YANG Xiuyuan, PENG Tao, YANG Liang*, LIN Hongfei

(College of Computer Science and Technology, Dalian University of Technology, Dalian 116023, Liaoning, China)

Abstract: An adaptive multi-domain knowledge distillation framework was proposed, which effectively accelerated reasoning and reduced model parameters while ensuring model performance. The knowledge distillation method was used to study sentiment analysis problems. When performing knowledge distillation for each specific field, model distillation involved word embedding layer distillation, coding layer distillation (attention distillation, hidden state distillation), output prediction layer distillation and other aspects of distillation, in order to learn all aspects knowledge from the specific field teacher model. Selectively learning the importance of the teacher model corresponding to different fields to the data was proposed, which further improved the accuracy of the prediction results. The experimental results on multiple public datasets showed that after single-domain knowledge distillation increased the model accuracy by an average of 2.39%, while multi-domain knowledge distillation increased the model accuracy by an average of 0.5%. Compared with the knowledge distillation of a single domain, this framework enhanced the generalization ability of the student model and improved the performance.

Key words: knowledge distillation; adaptive; multi-domain; sentiment analysis; deep learning

0 引言

预训练加微调,已成为自然语言处理任务中深度学习模型采用的主流方式。预训练模型,例如

ELMO (deep contextualized word representation)、BERT (bidirectional encoder representation from transformers)、XLNET、和 spanBERT^[1-4]在许多自然语言处理任务^[5]和具有挑战的多跳推理任务^[6]上取得了巨大成功。但是,预处理模型通常具有大量

收稿日期:2020-06-23; 网络首发时间:2021-05-14 16:06:25

网络首发地址:<https://kns.cnki.net/kcms/detail/37.1391.t.20210513.1324.002.html>

基金项目:国家重点研发计划资助项目(2018YFC0830604);国家自然科学基金资助项目(61702080,61806038);中央高校基本科研业务费专项(DUT19RC(4)016);中国博士后基金资助项目(2018M631788)

第一作者简介:杨修远(1995—),女,河南南阳人,硕士研究生,主要研究方向为情感分析。E-mail:liang@dlut.edu.cn

*通信作者简介:杨亮(1986—),男,辽宁大连人,讲师,博士,主要研究方向为情感分析,意见挖掘。E-mail:815754134@qq.com

的参数,并且需要较长的推理时间,例如,BERT(包含 24 层编码器,3.44 亿参数)、GPT-2(generative pre-training)(包含 48 层编码层,1.5 亿参数)无法直接部署到类似移动电话等资源受限的边缘设备上,或者是一些要求实时响应的设置中。此外,最近的研究也证明了预训练模型中有冗余^[7]。因此,如何在保证性能的同时减少预训练模型的计算开销和模型存储是一个至关重要的问题。

文献[8]提出了许多种模型压缩技术,在确保准确率的前提下,实现加速深度模型推理和减小模型参数。最常用的技术包括量化、权重裁剪^[9]、知识蒸馏。然而,在已有研究中,知识蒸馏模型通常只考虑单领域情况,忽略了学生模型可以同时接受多个领域教师模型监督,或者只是简单地将多个教师模型看作重要程度相同,无法根据教师模型之间的内在差异得到更有效的知识。为了解决这一问题,本研究提出了一个自适应多领域知识蒸馏的情感分析框架。

1 相关工作

知识蒸馏使用预训练的大网络模型作为教师模型,以一个参数量更少、运行速度更快的网络模型作为学生模型,通过模型训练最小化蒸馏损失函数,将知识从教师模型中传递到学生模型中,从而提升学生模型的识别性能。

知识蒸馏最先用于压缩分类模型。文献[10]提出基于相对熵散度的蒸馏准则指导学生模型的学习。进一步提出使用更“平缓”的教师模型后验概率分布指导学生模型。对于结构简单的神经网络,基于交叉熵(cross entropy, CE)的蒸馏准则可以明显提升学生模型的性能。但对于复杂任务的深度神经网络,仅使用 CE 准则对学生模型的性能提升有限。

对于深度神经网络,知识蒸馏除了学习教师模型最后的后验概率分布输出外,也可通过准则学习教师模型中间层的输出特征。例如:文献[11]利用教师模型隐层输出作为目标,学习学生模型的隐层输出;文献[12]提出使用 FSP(flow of solution procedure)矩阵衡量卷积层输出通道的信息,并使用欧式距离衡量教师与学生模型中间层输出特征的 FSP 矩阵的相似度作为蒸馏准则;文献[13]提出在中间层输出特征图中提取注意力图作为指导,使用欧式距离衡量教师学生模型两个注意力图的相似度作

为蒸馏准则。通过结合 CE 和这些设计的蒸馏准则,可以进一步提升学生模型的识别性能。

在知识蒸馏中,一般采用相比教师模型更简单的模型结构作为学生模型。近期也有研究发现,当教师与学生模型的模型结构一样时,知识蒸馏得到的学生模型可以取得比教师模型更好的识别性能^[14-16]。

2 特定领域的自适应知识蒸馏

2.1 模型框架

知识蒸馏框架,包含 3 部分:教师模型、学生模型、蒸馏目标。教师模型和学生模型结构一致,均选用 BERT 模型。

BERT 由多层的 Transformer^[17]层层叠加而成,方便模型获取关于输入数据之间的长距离依赖关系。每层 Transformer 则包含两个主要子层:多头注意力机制(multi-head attention, MHA)和位置前馈网络(feed-forward network, FFN),在两个子层的每一层周围采用残差连接^[18]和层归一。每个子层的输出为 $\text{LayerNorm}(x + \text{Sublayer}(x))$, $\text{Sublayer}(x)$ 是由子层本身实现的功能。为了保持子层之间能够连接,模型中的所有子层以及嵌入层均产生相同维度的输出。

子层 1:多头注意力机制的计算函数依赖于 3 个部分:检索(queries)、关键字(keys)、值(values)分别对应矩阵 Q 、 K 、 V 。计算公式如下:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (1)$$

多头注意力是指结合多个不同表征向量量子空间的注意力计算结果。其中 n 代表子空间的数量, h_i 代表第 i 个子空间中注意力计算后得到的向量。

$$\begin{cases} \text{MultiHead}(Q, K, V) = \text{Concat}(h_1, \dots, h_n) W^O \\ h_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \end{cases} \quad (2)$$

子层 2:位置前馈网络则是一个全连接的前向网络,即

$$\text{FFN}(Z) = \max(0, ZW_1 + b_1)W_2 + b_2. \quad (3)$$

教师模型选择预训练的基准 BERT 模型,包含 12 层 Transformer 结构,每层的隐藏向量为 768 维,前向传播的向量为 3072 维。学生模型选择裁剪后的 BERT 模型,包含 3 层 Transformer 结构,其余参数与教师模型保持一致。

2.2 自适应蒸馏目标

知识蒸馏的目标就是将大型的教师网络 M 中

的知识迁移到小型的学生模型 N 。学生模型网络将被训练去模仿教师网络的行为。 f^M 和 f^N 分别代表教师网络和学生网络的行为函数。行为函数的目标是将网络的输入转化成一贯的信息编码表示。形式上,知识蒸馏被建模成以下目标函数的最小化过程,即

$$L_{KD} = \sum_{x \in E} L(f^N(x), f^M(x)), \quad (4)$$

式中: $L(\cdot)$ 为衡量教师网络和学生网络之间差异的损失函数, x 为样本的输入, E 为样本集。因此,知识蒸馏的重点是构造有效的行为函数与之相关的损失函数。

基于 BERT 的知识蒸馏中,行为函数选择词嵌入层输出、编码层(注意力机制输出和中间隐藏状态)、预测层输出。损失函数选择最小均方差损失函数。

输出预测层蒸馏,如图 1 所示,使用教师模型中的最后一层输出作为软标签,即

$$y_i^M = \text{softmax}(z_i^M) = \frac{\exp(z_i^M)}{\sum_j \exp(z_j^M)}, \quad (5)$$

$$L_{\text{pred}} = \text{MSE}(y^M, y^N), \quad (6)$$

式中: y^M 为教师最后的输出状态。将该软标签作为行为函数,并且使用最小均方差函数去计算教师模型与学生模型之间的行为差距。




图 1 输出层蒸馏

Fig.1 Prediction-Layer distillation

在 Transformer 的编码层中,包含着许多中间变量。受到最近新研究的启发^[19],在 BERT 模型中,预训练得到的注意力分布权重可以捕捉到丰富的语言学知识,这类语言学知识包括了语法和单词之间的共现关系,这与自然语言理解极其相关。因此,借助基于注意力的蒸馏学习,帮助教师模型将其学习到的语言学知识迁移到学生模型中。学生可以通过学习教师的多头注意力矩阵,从而获取相关的知识,即

$$L_{\text{attn}} = \frac{1}{h} \sum_{i=1}^h \text{MSE}(\mathbf{A}_i^M, \mathbf{A}_i^N), \quad (7)$$

式中: h 为注意力的头数, $\mathbf{A}_i$ 为教师模型中第 i 个注意力头对应的注意力分布矩阵。与上述的蒸馏方法一样,使用最小均方差作为损失函数。在计算注意力相关的蒸馏损失函数中,注意力矩阵是未经过归一化处理的,即计算的 $\mathbf{A}_i$ 是未经过 Softmax 计算得到的。

关于 Transformer 的隐藏状态的知识蒸馏如图 2 所示。

$$L_{\text{hidden}} = \text{MSE}(H^M, H^N W_h), \quad (8)$$

式中: H^M 和 H^N 分别为学生和教师网络对应的隐藏状态。由于学生模型隐藏状态的维度与教师模型不一致,因此添加权重矩阵 W 对学生的隐藏状态进行线性变换,从而保证二者能在同一维度空间中计算最小均方差损失函数。




图 2 编码层蒸馏

Fig.2 Embedding-layer distillation

关于词嵌入层的知识蒸馏计算式为

$$L_{\text{embed}} = \text{MSE}(E^M, E^N W_e), \quad (9)$$

式中: E^S 和 E^T 分别为学生和教师网络对应的词嵌入层。

基于 BERT 的知识蒸馏目标包含了以上所有的行为函数。在各层中实施与之对应的蒸馏方法,即

$$L_{\text{model}} = \begin{cases} L_{\text{pred}}(N, M), & \text{layer} = 0 \\ L_{\text{hidn}}(N, M) + L_{\text{attn}}(N, M), & \text{Max} \geq \text{layer} > 0, \\ L_{\text{embd}}(N, M), & \text{Max} = \text{layer} + 1 \end{cases} \quad (10)$$

式中 Max 为最大层数。

上述蒸馏损失函数为教师模型软标签与学生模型软标签之间的交叉熵 L_{model} 。学生模型总损失函数由两部分组成。一部分是预测标签与真实标签之间的交叉熵 L_{CE} ,另一部分是蒸馏损失函数,即教师模型软标签与学生模型软标签之间的交叉熵 L_{model} 。 α 是可学习的,训练过程中将自适应地控制

两个损失函数的密度。

$$L=\alpha L_{\text{CE}}+(1-\alpha)L_{\text{model}}\circ$$

(11)

3 基于多领域的自适应知识蒸馏

本研究基于单领域知识蒸馏,结合多个领域知识,构造一个多领域自适应情感分析框架。多个领域包括电影评论、酒店评论、互联网评论等。训练数据表示为序列对 (x,y) ,其中 x 代表输入, y 代表目标标签。

分别训练多个不同领域的 BERT 教师模型。利用基于多领域对应的多个 BERT 模型,对单个学生模型进行进一步的蒸馏学习。下面将详细介绍模型框架与基于多领域知识蒸馏的过程。

3.1 模型框架

编码学生共享层如图 3 所示,多领域学习框架中,学生模型的词嵌入层和编码层对于不同的领域是共享的。通过编码共享层,学生模型对不同的数据集的输入 x 进行编码,生成包含上下文相关的隐藏状态。




图 3 多领域学习框架

Fig.3 Multi-domain learning framework

(1)特定领域学生输出层。学生模型对应不同的数据集,具有不同的输出层,比如针对电影评论领域,输出则为影评的情感极性;对于酒店评论领域,输出则为不同的酒店体验情绪。利用编码共享层生成的隐藏状态,将输入序列中特殊标识符[CLS]对应的隐藏状态当作输出层的输入,

$$P_i(\mathbf{c}|\mathbf{X}_i)=\text{softmax}(\mathbf{W}_i\mathbf{h}_i),$$

(12)

式中: $\mathbf{W}_i$ 为第 i 个领域对应的输出层权重系数, $P_i(\mathbf{c}|\mathbf{X}_i)$ 为第 i 个领域对应的类型的输出概率。

(2)特定领域教师模型。在模型框架中,对应不同的领域,微调 BERT 模型,生成教师模型。对于每个领域,教师模型的参数都不是共享的。利用不同的领域产生的特定教师模型,对同一个学

生模型,进行蒸馏学习。学生模型利用特定领域对应的真实标签,和教师模型基于 BERT 的方法进行蒸馏,即

$$L=\frac{1}{N}\sum_i^N(\alpha L_{\text{model}_i}+(1-\alpha)L_{\text{CE}_i}),$$

(13)

式中: N 为领域数目, L_{model_i} 和 L_{CE_i} 分别为第 i 个领域中的蒸馏损失函数和关于真实标签的交叉熵。

3.2 多领域蒸馏过程

本研究利用预训练的 BERT 模型初始化教师模型,并针对不同的数据集,微调出权重不共享的教师模型。接着,利用预训练的 BERT 模型的一些中间层去初始化学生模型。针对不同的领域,学生模型保持相同的编码器,即共享权重,然后利用不同的领域特定输出层输出领域对应的类别概率。

在多领域的蒸馏过程中,将所有领域对应的数据集合并成一个大数据集。大数据集每个批量(Batch)会包含不同领域的数据。针对每个 Batch,计算学生模型与对应教师之间的蒸馏损失函数和与目标结果的交叉熵,最终利用梯度传递更新学生模型。具体蒸馏过程如下:

算法 1 基于 BERT 的多领域蒸馏学习过程

```
输入  $N$ ; 训练集  $D_i$ ; 教师模型  $T_i; i \in [0, n]$ ;  $\text{epoch}_{\text{max}}$ 
预处理  $N$  个领域的数据集  $D_i$ 
for  $i = 1, 2, \dots, N$  do
    (1) 利用预训练 BERT 模型初始化教师模型  $T_i$ 
    (2) 利用训练数据  $D_i$  微调教师模型  $T_i$  至收敛
    (3) 保存教师模型  $T_i$ 
end
构建学生模型  $S$ , 并利用 BERT 进行初始化
设置迭代的最大次数为:  $\text{epoch}_{\text{max}}$ 
for epoch in  $1, 2, \dots, \text{epoch}_{\text{max}}$  do
    (1) 将所有数据集合并
         $D = D_1 \cup D_2 \dots \cup D_N$ 
    (2) 打乱数据  $D$ 
    for  $x$  in  $D$  do
        (3) 计算  $x$  对应的  $L_{\text{model}}$  和  $L_{\text{ce}}$ 
        (4) 梯度更新学生模型  $S$ 
    end
end
输出 学生模型  $S$ 
```

4 试验

4.1 试验数据

本研究选取不同领域的数据进行试验,包括中文产品评论、新闻内容、酒店评论3个领域。

NLPCC2014数据集来自NLPCC2014中的中文产品评论网站上评论情感分析领域,每条评论的极性都是二元的,正向或者负向。选取10 000条句子作为训练样本,2500条句子作为测试样本。

Inews为互联网新闻领域的情感分析数据,其情感极性为三元。具体例子:“1 _! _ 00005a3efe934a1 _! _ 九江办好人民满意教育 _! _ 近3 a来,九江市紧紧围绕“人本教育、公平教育、优质教育、幸福教育”的目标,努力办好人民满意教育,促进了义务教育均衡发展,农村贫困地区办学条件改善。目前,该市特色教育学校有70所...”。样本集每行为一条数据,以 _! _ 分割的字段,从前往后分别是情感类别、数据id、新闻标题、新闻内容。整个数据集包括训练集5356条样本,验证集1000条样本,测试集1000条样本。

ChnSentiCorp_htl_all是由谭松波教师收集整理的一份关于酒店评论的数据集,该领域情感极性为二元。具体例子:“1,环境位置很好,房间情况尚可,早餐一般般,价格偏高了一些。”样本集每行为一条数据,以“,”作为分割的字段,从前往后分别是评论类别、评论数据。整个数据包括5322条正向评论,2444条负向评论。对整个数据集的划分为训练集5766条样本、验证集1000条样本、测试集1000条样本。

4.2 数据增强

在蒸馏方法中,小数据集不足以充分体现教师模型的知识^[20]。因此,通过扩充训练集能够帮助有效地进行知识提取。

然而,自然语言处理中的数据增强通常比计算机视觉中的困难。首先,计算机视觉领域中存在大量同源的图像,例如,CIFAR-10是8000万个微型图像数据集的子集^[21]。其次,可以通过旋转,添加噪声和其他变形来合成接近自然的图像,但是如果手动操作自然语言的句子,可能会影响句子的流畅度,并且在一些自然语言处理任务中数据增强的有效性也并未得到验证。

采用与领域无关的方法进行数据增强:将小型数据集中的原始句子作为参照,使用启发式方法进行修改,类似图像失真。具体来说,数据样本随机执行以下操作。

遮蔽 以概率 p_{mask} 随机用“[MASK]”字符替换单词,对应于BERT模型中的遮蔽单词。直观地讲,此规则有助于阐明每个单词对标签的贡献(例如,教师网络对“我[MASK]喜剧”标签预测正确的概率要比“我喜欢喜剧”的概率小)。

同词性词替换 以概率 p_{pos} 用具有相同词性的单词替换单词。为保留原始的训练分布,将从通过词性重新归一化的单词分布中采样新词。此规则扰乱了有些句子原本的语义,例如,“我恨你!”与“我喜欢你!”。

N元采样 以概率 p_{ng} 随机抽取N元语句,其中N从{1,2,...,5}中随机选择。从概念上讲,此规则等同于删除样本中的所有其他单词,这是一种更具攻击性的遮蔽形式。

具体数据扩充过程如下:给定一个训练样本 $\{w_1, \dots, w_n\}$,由n个单词组成。服从均匀分布Uniform[0,1]迭代样本中的单词 w_i 。如果 $0 < X_i < p_{mask}$,对 w_i 进行遮蔽。如果 $p_{mask} \leq X_i < p_{mask} + p_{pos}$,将采用同词性的单词替换 w_i 。本研究假定遮蔽和同词性单词替换为互斥行为:一旦应用一个规则,另一个规则将被忽略。在遍历完单词之后,以概率 p_{ng} 将N元采样应用于整个合成样本。将得到的综合样本附加到扩展的、未标记的数据集。对每个样本执行 n_{iter} 次,从而生成最多 n_{iter} 个例子,其中所有重复项均丢弃。

4.3 试验参数设置

教师模型选用Google提供的12层BERT_{BASE}模型,内部包含12层Transformer,隐藏层维度为768,前向层维度为3072,模型总参数量为 1.09×10^8 ;将其剪裁至3层(保留其中的隐藏层0,6,11)作为学生模型,并保留其相关的预训练参数,使得总参数量只剩 4.00×10^7 。

在训练之前,对以上3个数据集进行数据增强。对于所有数据集,均采用 $p_{mask} = p_{pos} = 0.1$ 以及 $p_{ng} = 0.25$,选择 $n_{iter} = 10$ 来扩充数据。

本研究在3个数据集上的模型初始化学习率均为 $2.000\ 0 \times 10^{-5}$,迭代次数均为4。NLPCC2014数据集的输入截断长度为256,Bathch为8;Inews和ChnSentiCorp_htl_al数据集的输入截断长度为512,Bathch为8。按照以上的训练参数训练模型,分别为微调教师模型、微调学生模型、单领域蒸馏学生模型、多领域蒸馏学生模型。与BERT相同^[2],采用AdamW^[22]优化器优化模型,并将梯度裁剪的范围设置为[-1,1]。

在多领域学习的训练过程中,将所有数据集合

并成一个大数据集。每次随机产生其中一个数据集对应的 Batch, Batch 大小由上述设置决定。

4.4 试验结果与分析

- 试验选取了几种方法进行对比。
- (1) 卷积神经网络^[23]:卷积神经网络可以捕捉局部相关性,提取句子中类似 N 元关键信息。卷积核选取 3,4,5。
- (2) 循环神经网络^[24]:循环神经网络能够更好地表达上下文信息,其可以捕获到文本中变长且双向的 N 元信息。
- (3) Transformer:采用未加预训练的 Transformer 模型,与经过预训练的多层 Transformer 模型作比较。
- (4) 教师模型:经过预训练之后的 BERT 模型,并在各个领域进行微调。
- (5) 学生模型:未经蒸馏前的,将 BERT 剪裁至 3 层(保留其中的隐藏层 0,6,11)作为学生模型。
- (6) 单领域蒸馏模型:单领域进行知识蒸馏的 BERT 学生模型,包括嵌入层、编码层、预测输出层蒸馏。
- (7) 多领域蒸馏模型:经多个领域微调的 BERT 组合起来作为教师模型,训练单个多领域学生模型。

如表 1 所示,相比于 TextCNN 和 TextRNN 这类浅层模型,直接将 Transformer 作为文本分类模型的编码器,利用数据进行训练,模型准确率相比其他编码器是较差的。

表 1 不同模型在不同数据集上的准确度

Table 1 The accuracy of different architectures on different datasets %

模型	NLPCC2014	Inews	ChnSentiCorp_htl_al	平均
卷积神经网络	75.76	79.60	90.20	81.85
循环神经网络	78.15	77.50	90.70	82.12
Transformer	75.76	71.10	86.50	77.79
教师模型	82.59	84.78	91.79	86.39
学生模型	78.59	80.18	88.09	82.29
单领域蒸馏模型	80.75	82.08	91.09	84.64
多领域蒸馏模型	81.27	82.53	91.31	85.04

但是以 Transformer 模型为基础,并经过大规模语料预训练的深度表征模型 BERT,则有优异的性能表现(BERTBASE 三层(BERT(Student))),模型在各个任务上的准确率高于 Transformer。

从试验结果也可以清晰地看出,作为简化版的 BERT 模型,学生模型参数量减少一半,模型的性能也大幅度下降,模型在 3 个领域对应的数据集上准确度平均下降 4%左右。因此,在确保模型参数不变的前提下,对学生模型进行优化是有必要性的。

对学生模型进行单领域模型蒸馏,模型在 3 个领域上的准确度均有着明显的提高,NLPCC2014 提高了 2.26%,Inews 提高了 1.9%,ChnSentiCorp_htl_al 提高了 3%。

由于蒸馏前后模型使用相同的网络体系结构,并且使用相同的初始化和相同的数据集进行训练,因此推断模型性能的提升完全源于知识蒸馏。另外,对比数据增强前后的数据结果,学生模型准确率也有所提升,说明通过数据增强来扩充训练集规模有助于模型性能的提升。

基于多领域知识蒸馏,利用不同领域的数据集对学生模型的编码层进行统一的训练,提高学生模型的语义理解能力,增加了学生模型的泛化能力,实现了模型性能的进一步提高。NLPCC2014 提高了 0.52%,Inews 提高了 0.47%,ChnSentiCorp_htl_al 提高了 0.21%,平均提高了 0.4%。

通过对比表 1 中的不同模型准确率结果,可以看出基础模型性能的提升,一方面是因为通过知识蒸馏方法提取知识(来自个性化标志符),另一方面是因为自适应多领域知识蒸馏框架可以使学生模型自动有选择性地结合来自多个不同教师模型的知识,具有更强的泛化能力和语义理解能力。

4.5 消融试验

本研究基于 BERT 的蒸馏方法,由多个蒸馏方法构成。通过消融试验可以探究不同的蒸馏方法对整体模型的蒸馏准确率的影响。提出了几个基线,包括分别不进行输出层蒸馏、注意力蒸馏、隐藏层蒸馏、词嵌套蒸馏的模型学习。

试验结果如表 2 所示,可以看出,提出的所有蒸馏目标对于学生模型学习都是有效的。相比与其他的模型蒸馏方法,关于预测输出层的蒸馏学习对蒸馏效果的影响是最重要的,去掉输出层蒸馏,准确率下降 0.142%。而其他 3 个蒸馏方法,则相辅相成,使得基于 BERT 的蒸馏方法能够获得最大的性能提升。最后可以发现,使用基于多领域蒸馏学习的方法,也能有效提升模型性能。

表 2 不同蒸馏目标对应的模型准确率

Table 2 The accuracy of architectures with different distillation objectives %

模型	NLPCC2014	Inews	ChnSentiCorp_htl_al	平均
MT-Distill	81.27	82.53	91.31	85.04
Distil	80.75	82.08	91.09	84.64
-Distill	78.59	80.18	88.09	82.29
-pre_loss	78.55	81.28	88.99	82.94
-attn_loss	80.49	81.38	90.62	84.16
-hidden_loss	80.35	81.01	90.59	83.98
-embed_loss	80.71	81.56	90.42	84.23

5 结论

本研究提出了基于知识蒸馏的自适应多领域情感分析框架,结合多领域的信息,以打造模型参数量小、功能强大、通用性强的情感分析模型。具体而言,选定中文产品评论、新闻内容、酒店评论3个领域的数据集,并针对所有数据集进行一定的扩充;对于每个领域的数据,单独微调一个BERT模型;利用多领域对应的多个BERT模型(教师模型)对单个多领域模型(学生模型)进行进一步的蒸馏学习。其中知识蒸馏部分,包括词嵌入蒸馏、编码层蒸馏(注意力蒸馏、隐藏状态蒸馏)、输出预测层蒸馏多个方面的蒸馏。试验结果表明,与单领域的知识蒸馏相比,该框架增强了学生模型的泛化能力,提升了性能。

参考文献:

- [1] MATTHEW E, MARK N, MOHIT I, et al. Deep contextualized word representations [C]// Proceedings of NAACL-HLT. Stroudsburg, USA: Association for Computational Linguistics, 2018: 2227-2237.
- [2] DEVLIN J, CHANG M, LEE K, et al. Bert: pre-training of deep bidirectional transformers for language understanding [C]//Proceedings of NAACL-HLT. Stroudsburg, USA: Association for Computational Linguistics, 2019: 4171-4186.
- [3] YANG Z, DAI Z, YANG Y, et al. Xlnet: generalized autoregressive pretraining for language understanding [C]//Proceedings of NeurIPS. New York, USA: MIT Press, 2019: 5753-5763.
- [4] JOSHI M, CHEN D, LIU Y, et al. Spanbert: improving pre-training by representing and predicting spans [J]. Transactions of the Association for Computational Linguistics, 2019, 8(1): 64-77.
- [5] WANG A, AMANPREET S, JULIAN M, et al. Glue: a multi-task benchmark and analysis platform for natural language understanding [C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP). Brussels, Belgium: ACL, 2018: 353-355.
- [6] DING M, ZHOU C, CHEN Q, et al. Cognitive graph for multi-hop reading comprehension at scale [C]//Proceedings of the 57th Conference of the Association for Computational Linguistics. Florence, Italy: ACL, 2019: 2694-2703.
- [7] KOVALEVA O, ROMANOV A, ROGERS A, et al. Revealing the dark secrets of bert [C]//Proceedings of EMNLP-IJCNLP. Hong Kong, China: ACL, 2019: 4355-4365.
- [8] RASTEGARI M, ORDONEZ V, REDMON J, et al. Xnor-net: imagenet classification using binary convolutional neural networks [C]//European Conference on Computer Vision. Amsterdam, the Netherlands: Springer, 2016: 525-542.
- [9] HANG S, POOL J, TRAN J, et al. Learning both weights and connections for efficient neural network [C]//Proceedings of Neural Information Processing Systems (NeurIPS). New York, USA: MIT Press, 2015: 1135-1143.
- [10] LI J, ZHAO R, HUANG J, et al. Learning small-size DNN with output-distribution-based criteria [C]//Proceedings of Interspeech. Lyon, France: Interspeech, 2014: 1910-1914.
- [11] HUANG G, LIU Z, VAN D, et al. Densely connected convolutional networks [C]//Proceedings of the IEEE Conference on Computer vision and Pattern Recognition. Hawaii, USA: IEEE, 2017: 4700-4708.
- [12] YIM J, JOO D, BAE J, et al. A gift from knowledge distillation: fast optimization, network minimization and transfer learning [C]//Proceedings of CVPR. Hawaii, USA: IEEE, 2017: 7130-7138.
- [13] WOO S, PARK J, LEE J Y, et al. Cbam: convolutional block attention module [C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich, Germany: Springer, 2018: 3-19.
- [14] FURLANELLO T, LIPTON Z, TSCHANNEN M, et al. Born-again neural networks [C]//Proceedings of ICML. Stockholm, Sweden: ACM, 2018: 1602-1611.
- [15] YANG C, XIE L, SU C, et al. Snapshot distillation: teacher-student optimization in one generation [C]//Proceedings of CVPR. Long Beach, USA: IEEE, 2019: 2859-2868.
- [16] XU T, LIU C. Data-distortion guided self-distillation for deep neural networks [C]//Proceedings of AAAI. Hawaii, USA: AAAI, 2019: 5565-5572.
- [17] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of NIPS. New York, USA: MIT Press, 2017: 5998-6008.
- [18] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (NeurIPS). New York, USA: MIT Press, 2017: 770-778.
- [19] QIU X, SUN T, XU Y, et al. Pre-trained models for natural language processing: a survey [J]. Science China Technological Sciences, 2020, 29(2): 1-26.